

Project Description — Energy Theft Detection using Machine Learning

1. Project Overview

Energy Theft Detection là project phát hiện khách hàng có khả năng **trộm cắp điện** dựa trên lịch sử tiêu thụ điện hằng ngày. Bài toán được mô hình hóa thành **Supervised Binary Classification**, trong đó model dự đoán:

0 = normal customer

1 = theft customer

Dataset sử dụng: **SGCC Electricity Theft Detection Dataset** trên Kaggle. Dataset này được mô tả là dữ liệu mất cân bằng cho bài toán phát hiện trộm điện, gồm khoảng **42,372 dòng** và **1,037 cột**; nguồn mirror mô tả dữ liệu gồm **42,372 khách hàng** trong **1,035 ngày**, từ **01/01/2014 đến 31/10/2016**. ([Kaggle](#))

2. Input và Output của project

Thành phần	Mô tả cụ thể
Raw input	Lượng điện tiêu thụ theo ngày của từng khách hàng
Label	<code>flag</code> , với <code>0 = normal</code> , <code>1 = theft</code>
Final input cho model	Các feature được trích xuất từ chuỗi tiêu thụ điện
Final output	Xác suất khách hàng là theft, sau đó chuyển thành <code>0/1</code>

Final input không phải dữ liệu thô. Model sẽ học từ các feature như:

`mean_usage`, `median_usage`, `std_usage`, `variance_usage`,
`max_usage`, `min_usage`, `zero_usage_ratio`,
`average_daily_change`, `sudden_drop_ratio`

Các feature này phản ánh hành vi tiêu thụ bất thường, ví dụ: tiêu thụ giảm đột ngột, nhiều ngày bằng 0, hoặc mức dao động tiêu thụ bất thường.

3. Fundamentals cần dùng trong project

Fundamental	Cách dùng trong project
Data Pre-processing	Làm sạch dữ liệu, xử lý missing value, giá trị âm, giá trị lỗi
Central Tendency	Tạo <code>mean_usage</code> , <code>median_usage</code>
Dispersion	Tạo <code>std_usage</code> , <code>variance_usage</code> , <code>usage_range</code>
Binary Classification	Vì output chỉ có <code>normal</code> hoặc <code>theft</code>
Logistic Regression	Model chính để dự đoán xác suất theft
Maximum Likelihood Estimation	Giải thích cách Logistic Regression học tham số
Gradient Descent	Tối ưu loss function của Logistic Regression
Newton Method	So sánh với Gradient Descent về tốc độ hội tụ
Convex Optimization	Logistic Regression có loss convex, dễ tối ưu
Regularization	Dùng L2 để giảm overfitting
Bias-Variance Tradeoff	Phân tích underfitting / overfitting
Generalization	Đánh giá model trên test set
Discriminative Learning	Logistic Regression học trực tiếp $P(y x)$
Generative Learning	GDA học phân phối $P(x y)$
Gaussian Discriminant Analysis	Model so sánh với Logistic Regression
Linear Regression	Baseline phụ để chứng minh không phù hợp với classification

4. Method chính và model so sánh

Model chính

Logistic Regression

Lý do chọn:

- Phù hợp với **binary classification**.

- Dễ giải thích bằng toán học.
- Liên hệ tốt với MLE, Gradient Descent, Convex Optimization, Regularization.
- Có thể phân tích trọng số để biết feature nào ảnh hưởng đến dự đoán theft.

Model so sánh

Model	Vai trò
Logistic Regression	Model chính
Logistic Regression + L2	Kiểm tra tác dụng của regularization
Gaussian Discriminant Analysis	So sánh generative model với discriminative model
Linear Regression	Baseline phụ, dùng để giải thích vì sao regression không phù hợp

5. Metrics cần dùng

Vì dataset bị **imbalanced**, không nên đánh giá bằng Accuracy בלבד. Cần ưu tiên các metric liên quan đến class **theft**.

Metric	Vai trò
Accuracy	Chỉ dùng để tham khảo
Precision	Trong các cảnh báo theft, bao nhiêu là đúng
Recall	Trong các theft thật, model phát hiện được bao nhiêu
F1-score	Cân bằng Precision và Recall
ROC-AUC	Đánh giá khả năng phân biệt normal/theft
PR-AUC	Quan trọng khi class theft ít
Confusion Matrix	Phân tích TP, FP, TN, FN

Metric ưu tiên:

Recall, F1-score, PR-AUC

Lý do: trong bài toán này, **False Negative** là lỗi nguy hiểm nhất, vì đó là khách hàng thật sự trộm điện nhưng model dự đoán là normal.

6. Các bước thực hiện project

Bước	Việc cần làm cụ thể	Fundamentals dùng
1	Xác định bài toán: mỗi khách hàng được phân loại normal / theft dựa trên lịch sử tiêu thụ điện	Binary Classification, Supervised Learning
2	Kiểm tra phân phối class flag để xác định dữ liệu có mất cân bằng không	Data Understanding, Imbalanced Data, Metric Selection
3	Làm sạch dữ liệu: bỏ customer_id , tách flag , xử lý missing value, giá trị âm, giá trị lỗi	Data Pre-processing, Missing Value Handling
4	Tạo feature từ chuỗi tiêu thụ điện: mean, median, std, variance, zero ratio, sudden drop ratio	Central Tendency, Dispersion, Feature Engineering
5	Chuẩn hóa feature để các giá trị có cùng thang đo	Data Pre-processing, Gradient Descent
6	Chia dữ liệu thành train / validation / test, giữ tỷ lệ normal / theft tương tự nhau	Generalization, Bias-Variance Tradeoff
7	Train Logistic Regression baseline để dự đoán xác suất theft	Logistic Regression, MLE, Convex Optimization
8	Train Logistic Regression + L2 để kiểm tra khả năng giảm overfitting	Regularization, Bias-Variance Tradeoff
9	So sánh Gradient Descent và Newton Method qua tốc độ hội tụ, loss, metric validation	Gradient Descent, Newton Method
10	Train GDA để so sánh hướng generative với Logistic Regression	Generative Learning, GDA
11	Dùng Linear Regression làm baseline phụ, giải thích vì sao không phù hợp bằng Logistic Regression	Linear Regression, Model Suitability
12	Chọn threshold bằng validation set, ưu tiên Recall và F1-score	Threshold Tuning, Precision-Recall Tradeoff
13	Evaluate trên test set bằng Recall, F1-score, PR-AUC, ROC-AUC, Confusion Matrix	Model Evaluation, Generalization
14	Phân tích lỗi FN/FP và giải thích feature quan trọng của Logistic Regression	Error Analysis, Interpretability

7. Kết quả cần có trong báo cáo

Báo cáo nên trình bày:

- Mô tả dataset và tỷ lệ `normal/theft`.
 - Danh sách feature được tạo từ dữ liệu tiêu thụ điện.
 - So sánh các model: Logistic Regression, Logistic Regression + L2, GDA, Linear Regression baseline.
 - So sánh optimization: Gradient Descent và Newton Method.
 - Bảng metric: Accuracy, Precision, Recall, F1-score, ROC-AUC, PR-AUC.
 - Confusion Matrix để phân tích lỗi.
 - Nhận xét về Bias-Variance và Generalization.
 - Kết luận model nào phù hợp nhất và vì sao.
-

8. Project Description hoàn chỉnh

Project **Energy Theft Detection using Machine Learning** xây dựng mô hình phát hiện khách hàng có khả năng trộm cắp điện dựa trên dữ liệu tiêu thụ điện hằng ngày từ SGCC dataset. Bài toán được định nghĩa là **binary classification**, với output là `normal` hoặc `theft`.

Dữ liệu thô được xử lý qua các bước preprocessing, bao gồm xử lý missing value, loại bỏ giá trị lỗi và chuẩn hóa dữ liệu. Từ chuỗi tiêu thụ điện theo ngày, project trích xuất các feature thống kê và hành vi như mức tiêu thụ trung bình, độ lệch chuẩn, phương sai, tỷ lệ ngày tiêu thụ bằng 0 và tỷ lệ giảm tiêu thụ đột ngột.

Model chính là **Logistic Regression**, được giải thích bằng **Maximum Likelihood Estimation**, tối ưu bằng **Gradient Descent** và so sánh với **Newton Method**. Project sử dụng **L2 Regularization** để giảm overfitting và phân tích **Bias-Variance Tradeoff** để đánh giá khả năng generalization. Ngoài ra, project so sánh Logistic Regression với **Gaussian Discriminant Analysis** để làm rõ khác biệt giữa discriminative learning và generative learning.

Vì dữ liệu mất cân bằng, project không chỉ dùng Accuracy mà ưu tiên **Recall, F1-score, PR-AUC và Confusion Matrix**. Mục tiêu cuối cùng là xây dựng một model đơn giản, giải thích được, và có khả năng phát hiện tốt các trường hợp trộm điện thật.